




제7장 불확실성

학습 목표

- 불확실성의 개념과 기본 확률 이론을 이해한다.
- 베이즈 추론을 이해한다.
- 전문가 시스템에서 사용되는 확신도 시스템을 이해한다.

01 불확실성

- 고전적인 논리를 이용하여 추론을 하려면 규칙의 전체 조건이나 결론이 항상 참이거나 거짓이어야 한다. 즉 100% 확실하여야 한다.
 - IF A is true
 - THEN B is true
- 현실 세계에서 100% 확실한 정보나 지식을 얻는다는 것은 상당히 힘들다. 따라서 우리가 사용하는 정보나 지식은 항상 어느 정도 불확실하다고 할 수 있다.

불확실성의 예

- 집에서 공항까지 가서 탑승하는 문제
 - 중간에 자동차가 고장 날 수도 있고,
 - 엄청난 차량 정체를 겪을 수도 있다.
 - 공항이 몹시 혼잡하여서 수속에 시간이 많이 걸릴 수도 있다.





그림 7-1 불확실성이 발생하는 문제

불확실성의 예

- 내과에서 환자를 진단하는 전문가 시스템
 - 규칙: 감기이다 → 열이 있다. -> 100% 확실할 수 없다.



불확실성은 왜 발생하는 것인가?

- **데이터의 불확실성**: 센서로부터 얻는 데이터는 장치의 측정 오류나 오차 때문에 완전하지 못하다.
- **지식의 불완전성**: 전문가로부터 얻는 지식은 완전하지 않을 수 있다. 문제 영역 자체가 불확실할 수도 있다. 예를 들어서 주식 예측이나 부동산 투자의 경우에는 문제 자체에 불확실성이 존재한다.
- **전문가들의 관점이 다른 경우**: 전문가들마다 의견이 다를 수 있다.
- **정보 획득의 불완전성**: 정보 자체를 모두 수집하거나 처리할 수 없기 때문에 불확실성이 발생한다. 예: 자율주행의 환경 정보
- **부정확한 언어**: 인간이 사용하는 자연어에는 모호한 단어가 많다.

인공지능 시스템에서의 불확실성 처리

- 불확실한 지식이나 정보를 가지고도 올바른 결정을 내릴 수 있어야 한다.
 - 인공지능 시스템에서는 참과 거짓이 아니라 믿음의 정도(degree of belief)를 제공
- 믿음의 정도(또는 가능성)를 다루는 수학적 도구는 확률 이론(probability theory)이다.
- 불확실성을 처리하는 대표적인 2가지 방법
 - 베이즈 추론(Bayesian reasoning)
 - 확신도(certainty factor)

02 확률을 이용한 불확실성 처리

- 확률적인 추론(probabilistic reasoning)에서는 명제의 진리값이 0(거짓) 또는 1(참)이 아니고 0.0에서 1.0 사이의 값을 가진다.
 - 확률적인 추론에서는 가장 확률이 높은 결론이 선택된다.
- 주사위 한번 던지기 실험에서 1과 3이 나오는 사건은 상호 배타적인 사건
 - 동시에 일어날 수 없는 사건, 둘 중 하나만 발생할 수 있는 사건. 독립적이지 않음
 - 한 사건이 발생하면 다른 사건은 반드시 발생하지 않으며, 두 사건의 교집합이 **빈 집합**: $P(A \cap B) = 0$
 - 주사위 한번 던질 때 **짝수**가 나오는 사건과 **홀수**가 나오는 사건은 상호 배타적
 - **조건부 확률은 상호 배타적이지 않은 경우: 교집합이 0이 아닌 경우**
- 상호 독립적
 - A가 일어난 일이 B가 일어나는 확률에 영향을 주지 않는 경우
 - 주사위 던지기와 동전 던지기는 상호 독립적, 주사위 두 번 던지기도 독립적
 - 조건부 확률을 적용할 수 있지만, 원래 확률과 같음
 - $P(A|B) = P(A)$, $P(A \cap B) = P(A) \times P(B)$



조건부 확률

- $p(A|B)$
 - 사건 B가 발생했을 때, 사건 A가 발생할 확률
- $p(A \cap B)$
 - A와 B의 결합 확률
 - A와 B가 동시에 발생할 확률

사전 확률과 사후 확률

$$p(A|B) = \frac{A \text{와 } B \text{가 동시에 발생할 경우의 수}}{B \text{가 발생할 경우의 수}}$$

$$p(A|B) = \frac{p(A \cap B)}{p(B)}$$

$$p(B|A) = \frac{p(A \cap B)}{p(A)}$$

$$p(A \cap B) = p(B|A) \times p(A)$$

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

베이지 규칙 (Bayes Rule)

The diagram shows the Bayes' Rule formula:
$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$
 Red arrows point from labels to parts of the formula: '가능도 (likelihood)' points to $p(B|A)$, '사후확률 (posterior)' points to $p(A|B)$, '사전확률 (prior)' points to $p(A)$, and '사전확률 (evidence)' points to $p(B)$.

가능도 (likelihood)

사후확률 (posterior)

사전확률 (prior)

사전확률 (evidence)

- 베이지 정리
 - 계산하기 쉬운 사후 확률(가능도)을 이용하여서 계산하기 어려운 사후 확률을 계산하는 방법
 - $p(A|B)$ 를 직접 계산하기는 힘들 경우에는, 상대적으로 계산하기 쉬운 $p(B|A)$, $p(A)$, $p(B)$ 를 이용하여 계산하는 방법

베이즈 정리

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

a가 일어날 확률 * a가 일어났을 때 b가 일어날 확률 + a가 일어나지 않을 때 b * a가 일어나지 않을

$$p(B) = p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)$$



$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)}$$

Confusion Matrix

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{TP + FN}$ recall
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{TN + FP}$
		Precision $\frac{TP}{TP + FP}$	Negative Predictive Value $\frac{TN}{TN + FN}$	Accuracy $\frac{TP + TN}{TP + TN + FP + FN}$

- Recall(재현율, 민감도): 얼마나 실제 참이 예측되었는가? 실제 True 중 모델이 True 로 예측한 비율
- Precision(정밀도): 얼마나 예측이 실제 참을 찾아내는가? 모델이 True 라고 한 것 중 실제 True 비율
- Specificity(특이도): 실제 negative 중 negative로 맞게 판정하는 비율

- F1 Score
 - 정밀도(Precision)와 재현율(Recall)의 조화평균(Harmonic Mean)
 - $F1\ Score = 2 * (Precision * Recall) / (Precision + Recall)$
- F1 Score는 다음과 같은 상황에서 특히 유용
 - 데이터 불균형(Imbalanced Data)이 심할 때
 - 예: 스팸 메일 분류 (스팸 1%, 정상 메일 99%). 단순히 '정상 메일'이라고만 예측해도 정확도(Accuracy)는 99%지만, 이는 무의미함. F1 Score는 스팸을 찾아내는 성능을 제대로 평가함
 - False Negative(FN)와 False Positive(FP) 모두 중요할 때
 - 예: 암 진단, 금융 사기 탐지 등. (FN: 환자를 놓침, FP: 건강한 사람을 불안하게 함)
 - 정밀도와 재현율 중 하나만 높은 '치팅' 모델을 걸러낼 때

Lab: Z-바이러스 1

- 세계의 인구의 10%가 Z-바이러스에 감염되었다.
- Z-바이러스 감염자이면 90% 확률로 positive로 판정한다. 민감도 (Sensitivity). Recall (Type II error 포함)
- Z-바이러스 감염자가 아니면 70%의 확률로 negative로 판정한다. 특이도 (Specificity)
- 어떤 개인이 검사를 하였는데 positive로 나왔다면 이 개인이 좀비일 확률은 얼마나 될까?



	P	N
P	TP 0.9	FN 0.1
N	FP 0.3	TN 0.7

Lab: Z-바이러스 1

$$\begin{aligned}P(\text{Zombie}|+) &= \frac{P(+|\text{Zombie})P(\text{Zombie})}{P(+)} \\&= \frac{P(+|\text{Zombie})P(\text{Zombie})}{P(+|\text{Zombie})P(\text{Zombie}) + P(+|\neg\text{Zombie})P(\neg\text{Zombie})} \\&= \frac{0.90 \times 0.1}{0.90 \times 0.1 + 0.30 \times 0.90} \\&= 0.25\end{aligned}$$

	P	N
P	TP 0.9	FN 0.1
N	FP 0.3	TN 0.7

Lab: Z-바이러스 2

$P(+|D)$: 감염자에 대해서 시약을 적용해서 positive로 나온 비율이다(95%)

$P(D)$: 전체 인구 중에서 감염자의 비율이다(1%).

$P(\neg D)$: 전체 인구 중에서 비감염자의 비율이다(99%).

$P(+|\neg D)$: 비감염자에 대해서 시약을 적용해서 positive로 나온 비율이다(2%)

$P(D|+)$: positive로 나왔을 때, 실제 감염자인 확률이다. 우리가 알고 싶은 확률이다.

	P	N
P	TP 0.95	FN 0.05
N	FP 0.02	TN 0.98

Lab: Z-바이러스 2

$$P(+|D): 0.95$$

$$P(D): 0.01$$

$$P(\neg D): 0.99$$

$$P(+|\neg D): 0.02$$

	P	N
P	TP 0.95	FN 0.05
N	FP 0.02	TN 0.98

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|\neg D)P(\neg D)} = \frac{0.95 \times 0.01}{0.95 \times 0.01 + 0.02 \times 0.99} \approx 0.32$$

Lab: Z-바이러스 2

- 만약 시약이 위양성(false-positive)이 없다면 이 사람은 100% 감염된 것으로 판정된다.

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|\neg D)P(\neg D)} = \frac{0.95 \times 0.01}{0.95 \times 0.01 + 0.00 \times 0.99} \approx 1.0$$

Lab: 과일 문제

- 그릇 #1에는 사과 10개와 바나나 30개가 있으며 그릇 #2에는 사과와 바나나가 각각 20개가 있다. 어떤 사람이 그릇을 무작위로 골라 과일을 무작위로 선택한다고 하자. 어떤 사람이 선택한 과일이 바나나로 판명되었다. 그 사람이 그릇 #1에서 바나나를 선택했을 가능성은 얼마나 될까?



사과 10개
바나나 30개



사과 20개
바나나 20개

Lab: 과일 문제

$$\begin{aligned} p(H_1|E) &= \frac{p(E|H_1) \times p(H_1)}{p(E|H_1) \times p(H_1) + p(E|H_2) \times p(H_2)} \\ &= \frac{0.75 \times 0.5}{0.75 \times 0.5 + 0.5 \times 0.5} = 0.6 \end{aligned}$$



사과 10개
바나나 30개



사과 20개
바나나 20개

Q

- 공이 들어 있는 두 개의 항아리가 있다. 첫 번째 항아리에는 빨간 공 50개와 파란 공 50개가 들어 있다. 두 번째 항아리에는 30개의 빨간 공과 70개의 파란 공이 들어 있다. 두 항아리 중 하나가 무작위로 선택되고, 선택된 항아리에서 공을 무작위로 뽑는다. 빨간 공이 뽑혔을 때 첫 번째 항아리에서 선택되었을 확률은 얼마인가? 베이즈 규칙을 사용하여 계산하라.

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)}$$

Lab: 카드 게임

- 우리가 한 장의 카드를 가지고 있는데 카드에 얼굴이 그려져 있다는 것만 알고 있다. 이 상황에서 이 카드가 킹(king)일 확률을 추론해보자. 즉 $P(\text{King} \mid \text{Face})$ 확률을 계산해보는 것이다.



j Q K

Lab: 카드 게임

$$P(King|Face) = \frac{P(Face|King)P(King)}{P(Face)}$$

$$P(King|Face) = \frac{P(Face|King)P(King)}{P(Face)} = \frac{13}{3} \frac{1}{13} = \frac{1}{3}$$



03 베이지 정리와 추론

- 전문가 시스템의 규칙
 - IF E is true
 - THEN H is true (확률: p)
- (예) $p(H|E)$
 - IF 기침을 한다.
 - THEN 감기이다. (확률: 0.7)
- 규칙의 확률 계산은 어떻게?
 - 통계 자료(사전확률, 가능도, ...)가 제공되어야 베이지 정리로 확률 계산 가능

베이즈 정리와 추론

$$p(H|E) = \frac{p(E|H) \times p(H)}{p(E|H) \times p(H) + p(E|\neg H) \times p(\neg H)}$$

증거가 있을 때 가설이 참일 확률

- $P(H)$ - 가설 H 가 참일 확률(사전 확률)
- $P(\neg H)$ - 가설 H 가 거짓일 확률(사전 확률)
- $p(E|H)$ - 가설 H 가 참일 때, 증거 E 가 나타날 확률(가능도)
- $p(E|\neg H)$ - 가설 H 가 거짓임에도, 증거 E 가 나타날 확률(가능도)

위의 사전 확률과 가능도는 누가 제공해야 하는 것일까?

- 전문가 시스템에서 사용되는 규칙이라면 전문가들이 이들 확률을 제공해야 한다.

E

- 가설이 나타날 확률 $P(H)$
- 가설이 나타나지 않을 확률 $P(\neg H)$
- 가설이 참일 때 증거가 나타날 확률 $p(E|H)$
- 가설이 거짓일 때, 증거 E 가 나타날 확률 $p(E|\neg H)$
- 의사와 같은 전문가라면 제공할 수 있는가?



증거와 가설이 여러 개일 때

(예) 가설이 상호 배타적(동시에 일어나지 않는 사건)이어야 계산 가능

- IF 기침을 한다.(E)
- THEN 감기이다. (H1)

같은 증거에 대해서 가설이 여러 개 일수도 있다.

- IF 기침을 한다. (E)
- THEN 폐렴이다. (H2)

감기이면서 폐렴이면 안된다, 서로 분리가 되어야 한다.

1/3 분할

$$p(H_i|E) = \frac{p(E|H_i) \times p(H_i)}{\sum_{k=1}^m p(E|H_k) \times p(H_k)}$$

베이즈 정리의 단점

- 베이즈 추론이 정확한 결과를 도출하려면 사전 확률과 같은 확률값이 입력되어야 한다.
- 어떤 분야에서는 믿을만한 통계 자료가 없어서 사전 확률을 산정할 수 없는 경우도 있다. 예를 들어서 의학 분야에서는 이러한 자료를 얻기가 상당히 힘들다.

베이즈의 장점 : 정확하다 , 하지만 사전 자료가 주어져야 한다.

Lab: 베이지 정리로 규칙의 확률 계산

- 규칙

$$P(\text{충치} | \neg \text{치통}) = P(\text{치통}) \cdot P(\neg \text{충치} | \text{치통}) + P(\neg \text{치통}) \cdot P(\neg \text{충치} | \neg \text{치통})$$

IF 치통이 있다.
THEN 충치이다. (확률: ???)

	치통	¬치통
충치	0.04	0.06
¬충치	0.01	0.89

Confusion Matrix 아님


Lab:베이지 정리로 규칙의 확률 계산 실습

$$P(\text{충치} | \text{치통}) = \frac{P(\text{충치} \wedge \text{치통})}{P(\text{치통})} = \frac{0.04}{(0.04 + 0.01)} = 0.8$$

$$P(\neg \text{충치} | \text{치통}) = \frac{P(\neg \text{충치} \wedge \text{치통})}{P(\text{치통})} = \frac{0.01}{(0.04 + 0.01)} = 0.2$$


IF 치통이 있다.
THEN 충치이다. (확률: 0.8)

	치통	¬치통
충치	0.04	0.06
¬충치	0.01	0.89



Lab:스팸 필터링

- 조건부 확률 계산 $P(\text{spam}|\text{word})$
- 전체 메일 중에 40%가 스팸 메일이다.
- 스팸 메일 중의 1%가 제목으로 특정한 word를 가진다.
- 정상 메일 중의 0.4%가 제목으로 특정한 word를 가진다.
- 메일의 제목에 특정 word가 있을 때 스팸일 확률은?



Lab:스팸 필터링

$$P(spam|word) = \frac{P(word|spam) \times P(spam)}{P(word|spam) \times P(spam) + P(word|\neg spam) \times P(\neg spam)}$$

- 여기서 $P(spam) = 0.4$ 이고 $P(word|spam) = 0.01$ 이다. 또 $P(word|\neg spam)$ 은 0.004, $P(\neg spam)$ 은 0.6이다. 따라서 다음과 같은 결과를 얻는다.

$$P(spam | word) = \frac{0.004}{(0.0064)} = 5/8 = 0.625$$

Q


- 어떤 컨설팅 회사가 경기 침체를 예측하는 수학적 모델을 만들었다. 모델은 경기 침체가 실제로 발생할 때 80%의 확률로 경기 침체를 예측하고, 경기 침체가 없을 때 10%의 확률로 경기 침체를 예측한다. 경기 침체에 빠질 사전 확률은 20%이다. 이 모델이 경기 침체를 예측한다면 경기 침체가 실제로 일어날 확률은 얼마인가? 베이즈 규칙을 사용해서 계산하라.

0.6
2
3

	P	N
P	TP 0.8	FN 0.2
N	FP 0.1	TN 0.9


Lab: 몬티홀 문제

- 세계적인 공학자 5000명을 혼란에 빠뜨린 유명한 확률 문제가 있다. 바로 몬티 홀 문제(Monty Hall problem)이다.
- 사용자가 맞추면 상품을 주는 퀴즈쇼(Let's Make a Deal)가 있다. 이 게임쇼에서는 세 개의 문 중에서 하나를 선택할 수 있다. 하나의 문 뒤에는 자동차가 있고 다른 문들 뒤에는 염소가 있다.




Lab: 몬티홀 문제

- 사용자가 1번 문을 선택하면 그 문 뒤에 무엇이 있는지 아는 사회자 (Monty Hall)가 염소가 있는 문(3번문이라고 하자.)을 연다. 그런 다음, 사회자는 당신에게 선택을 바꿀 기회를 준다.
- 선택을 바꾸는 것이 사용자에게 유리할까? 그대로 있는 것이 유리할까?



Lab: 몬티홀 문제

- 직관적인 설명: 일단 참가자가 1 번 문을 선택하였고 자동차가 각 문 뒤에 있었을 3가지의 경우를 생각할 수 있다.




Lab: 몬티홀 문제

- 베이지 정리를 이용해보자.

$$P(\text{문2에 자동차} | \text{사회자 문3 열음}) = \frac{P(\text{사회자 문3 열음} | \text{문2에 자동차}) P(\text{문2에 자동차})}{P(\text{사회자 문3 열음})}$$

$$P(\text{문2에 자동차} | \text{사회자 문3 열음}) = \frac{1 * (1/3)}{(1/2)} = \frac{2}{3}$$



Lab: 몬티홀 문제

```
import random

NGames=10000
UnchangeGame=[]
ChangeGame=[]

for i in range(0, NGames):

    # 자동차는 랜덤하게 숨겨진다.
    CarDoor=random.choice(["Door1", "Door2", "Door3"])
    # 사용자가 첫 번째 선택을 한다.
    UserDoor=random.choice(["Door1", "Door2", "Door3"])
    # 호스트가 자동차가 있지 않은 문을 연다.
    OpenDoor=list(set(["Door1", "Door2", "Door3"])-set([UserDoor, CarDoor]))[0]
    # 남아 있는 문을 결정한다.
    OtherDoor=list(set(["Door1", "Door2", "Door3"])-set([UserDoor, OpenDoor]))[0]

    # 사용자가 선택을 바꾸지 않아서 성공하면 True를 리스트에 추가한다. True는 정수 1이다.
    UnchangeGame.append(UserDoor==CarDoor)
    # 사용자가 선택을 바꾸어서 성공하면 True를 리스트에 추가한다. True는 정수 1이다.
    ChangeGame.append(OtherDoor==CarDoor)

# 각 리스트에서 정수 1의 개수를 센다.
print(f"{NGames} 개의 게임 중에서 바꾸지 않았을 때의 승률: {sum(UnchangeGame)/NGames} \n\
      바꾸었을 때의 승률: {sum(ChangeGame)/NGames}")
```


Lab: 몬티홀 문제

10000 개의 게임 중에서 바꾸지 않았을 때의 승률: 0.3313

바꾸었을 때의 승률: 0.6687

04 확신도

- 베이지 추론의 대안으로 가장 잘 알려져 있는 것은 **확신도**(certainty factor)이다. 베이지 추론은 사전 확률이 있어야만 한다.
- 확신도는 MYCIN이라는 전문가 시스템에서 사용됨
- MYCIN은 박테리아 감염을 진단하고 치료하는 전문가 시스템
- 확률 이론을 사용하기 위해서는 너무 많은 조건부 확률이 필요



확신도

- 확신도는 전문가들의 신뢰도를 나타내는 수치이다.
- 확신도는 -1.0에서 +1.0까지 줄 수 있다.
 - -1.0값은 확실한 거짓이라는 것을 의미하고 +1.0 값은 확실한 참을 의미한다.

IF	E (증거)
THEN	H (가설, cf: +0.8)

cf: certainty fac

IF	1) The stain of the organism is gram positive, and 2) The morphology of the organism is coccus, and 3) The growth conformation of the organism is chains
THEN	There is suggestive evidence (0.7) that the identity of the organism is streptococcus

확신도의 계산

- $cf[H, E] = MB(H, E) - MD(H, E)$ - / ~ /
 - $cf[H, E]$ 는 증거 E 를 가지고 있을 때, 가설 H 에 대한 확신도이다.
 - $MB[H, E]$ 는 E 가 H 를 지지하는 정도를 측정한다.
 - Measure of Belief 믿음의 정도
 - $MD[H, E]$ 는 E 가 H 의 부정을 지지하는 정도를 측정한다.
 - Measuere of Disbelief 불신의 정도
- MYCIN에서 MB 와 MD 는 전문가인 의사들이 배정하는 확률로 정의된다. 따라서 이들은 모두 0에서 1 사이의 값을 가진다. 따라서 cf 는 -1과 1 사이의 값을 가진다. cf 가 1을 향함에 따라 증거는 점점 가설을 지지한다.

확신도의 계산

- MYCIN에서는 어떤 규칙이 점화되기 위해서는 확신도가 문턱값을 넘어야 한다. 이때 불신의 정도인 MD가 영향을 심하게 끼치게 된다.

$$cf = 0.2$$

- 예를 들어서 어떤 규칙의 MB = 0.8 이고 MD = 0.6이라고 하자. 이 규칙이 점화되기 위한 확신도의 문턱값은 0.25라고 하자. 이 규칙은 MB가 0.8이나 되지만 점화될 수가 없다. MD도 상당히 높기 때문이다.

- 이 단점을 방지하기 위하여 확신도의 정의를 다음과 같이 변경한다.
 - $cf[H, E] = (MB - MD) / (1 - \min(MB, MD))$
 - $(0.8 - 0.6) / (1 - \min(0.8, 0.6)) = 0.2 / 0.4 = 0.5$

불확실한 증거를 가진 규칙에서의 확신도

- 불확실한 증거를 가진 규칙에서의 확신도
 - IF E (불확실한 증거) 증거가 불확실하면 확신도를 전문가가 정해준다
 - THEN H (가설)
- $cf(H, e) = cf(E, e) \times cf(H, E)$
- (예)
 - IF 하늘이 흐리다.(불확실한 증거)
 - THEN 비가 온다.(가설, $cf=0.8$)
 - $cf(E, e)$: 불확실한 증거 e에 의한 증거 E의 확신도 확실하게 흐린 게 아니다.
 - 규칙의 전제인 “하늘이 흐리다”의 확신도가 0.6 그래서 전문가가 0.6으로 정해줌
 - $cf(H, e) = cf(E, e) \times cf(H, E) = 0.6 \times 0.8 = 0.48$

규칙이 여러 개의 전제를 가지는 경우

- AND로 연결되는 경우
 - IF E1 AND E2
 - THEN H (가설, cf)
 - $cf(H, E1 \cap E2) = \min(cf(E1), cf(E2)) \times cf(H, E)$
- OR로 연결되는 경우
 - IF E1 OR E2
 - THEN H (가설, cf)
 - $cf(H, E1 \cup E2) = \underline{\max}(cf(E1), cf(E2)) \times cf(H, E)$
or로 연결되면 max

규칙이 여러 개의 전제를 가지는 경우

- 규칙
 - IF 0.5 0.6
 하늘이 흐리다. OR 비가 온다.
 - THEN 우산을 준비한다.(cf 0.9)
- “하늘이 흐리다”의 확신도는 0.5, “비가 온다”의 확신도는 0.6
- “우산을 준비한다”는 가설의 확신도는 다음과 같이 계산할 수 있다.
 - $cf(H, E1 \cup E2) = \max(0.5, 0.6) \times 0.9 = 0.54$

Lab: 확신도 계산

- 확신도를 가지고 여러 가지 계산을 해보자. 만약 다음과 같이 규칙의 증거가 여러 증거들의 조합이라고 할 때, 규칙의 확신도는 어떻게 계산해야 하는가?

IF (E1 AND E2 AND E3) OR (E4 AND NOT E5)
THEN H

Handwritten notes: A blue circle is drawn around E3, with m_j written below it. A blue arrow points from the circle to the text "부호를 바꿔준다".

- 구체적인 수를 가지고 계산해보자. $E1 = 0.8$, $E2 = 0.9$, $E3 = 0.1$, $E4 = -0.4$, $E5 = -0.5$ 라고 하면 전체 증거의 확신도는 다음과 같다.

$$E = \max(\min(0.8, 0.9, 0.1), \min(-0.4, -(-0.5)))$$
$$= \max(0.1, -0.4)$$

Handwritten calculations:

$$\min(0.8, 0.9) = 0.1$$
$$\min(0.1, 0.5) = 0.1$$
$$\max(-0.4, 0.5) = 0.5$$

Summary

- 확률 이론은 전문가 시스템에서 불확실성을 다룰 수 있도록 수학적으로 정확한 접근법을 알려준다. **베이즈 추론**이 대표적인 예이다.
- 사전 확률이 있어야 한다.
베이즈 추론이란 "IF 증거 THEN 가설"에서 **증거의 확률**이 주어지는 경우에 가설의 신뢰도를 조건부 확률로 계산하는 방법이다.
- **확신도 이론**은 베이즈 추론의 대안으로 많이 사용된다. 박테리아 감염을 진단하는 MYCIN에서 사용하였다. 확신도 이론이란 "IF 증거 THEN 가설"에서 증거의 확신도가 주어지는 경우에 가설의 신뢰도를 확신도 형태로 계산하는 방법이다.

Q & A

